

# TS115 Rapport de TP

Oumaima Najib

May 2021


## 1 Variable aléatoire gaussienne univariée

### 1.1 Manipulation 1

La variable aléatoire gaussienne  $Y$  de moyenne  $\mu$  et de variance  $\sigma$  est paramétrée en utilisant la formule :  $\mu + \sigma \times X$ , avec  $X \sim N(0, 1)$ .

On a utilisé la normalisation de type 'pdf'.  $c_i$  est le nombre d'élément dans chaque bin, c'est à dire le nombre de fois ou ont été générés des  $x$  appartenant à  $[x_i, x_i + 1]$ ,  $w_i$  correspond à la largeur du bin. Et  $N$  correspond au nombre de réalisations : La valeur assigné à chaque bin est égal à :

$$\hat{f}_X(x) = \frac{c_i}{N \times w_i}.$$



Avec cette normalisation, la hauteur de chaque bin  $v_i$  est égal à la probabilité

de sélectionner une observation se trouvant dans l'intervalle du bin, la somme des aires sous les barres est donc égal à 1.

## 1.2 Manipulation 2

L'expression de l'entropie dans le cas d'une variable aléatoire continue est :

$$H(X) = - \int_{-\infty}^{\infty} f_X(x) \log(f_X(x)) dx$$

avec  $f_X$  la densité de probabilité de  $X$ .

Pour obtenir l'entropie de la variable aléatoire générée, on calcule l'aire sous les bins obtenue dans l'histogramme, avec multiplication par  $-\log(v_i)$ . La somme continue est remplacée par une somme discrète sur les valeurs estimées de  $f_X$ , ici les  $v_i$ . On multiplie cette somme par la largeur des bins de l'histogramme pour obtenir le bon résultat. On obtient une valeur proche de 2.51, qui est la valeur théorique de l'entropie d'une variable aléatoire gaussienne de variance 9.

$$H = \ln(\sigma\sqrt{2\pi} * e) = 2,51.$$

## 2 Variable multidimensionnelle aléatoire gaussienne

### 2.1 Question 1

Soit  $\Sigma$  la matrice, au vu de l'indépendance, diagonale de covariance de la variable aléatoire gaussienne à  $P$  composantes, et  $\mu$  le vecteur représentant son centre.

On note  $X$  le vecteur gaussien dans  $R^p$  :  $X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}$  avec  $X_1, X_2, \dots, X_p$  les

composantes de  $X$ .

Son espérance s'écrit :  $\mu = \begin{bmatrix} E[X_1] \\ E[X_2] \\ \vdots \\ E[X_p] \end{bmatrix}$  et sa matrice de covariance :

$$\Sigma = E[(X - E[X])(X - E[X])^\top] = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) & \cdots & Cov(X_1, X_p) \\ Cov(X_2, X_1) & Var(X_1, X_2) & \cdots & Cov(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(X_p, X_1) & Cov(X_p, X_2) & \cdots & Var(X_p) \end{bmatrix}$$

Comme les variables aléatoires sont indépendantes et de même variance :

$$\Sigma = \begin{bmatrix} \sigma & 0 & \cdots & 0 \\ 0 & \sigma & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma \end{bmatrix}$$

avec  $\sigma$  la variance de  $X_1$ .

La loi gaussienne est donnée par :

$$f_X(x) = \frac{1}{(2\pi)^{P/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right]$$

## 2.2 Question 2

On le démontre en comparant les fonctions caractéristiques de  $\Sigma_y^{1/2}X + \mu$  et  $Y$  où  $X \sim N(0, I)$ . En effet, la fonction caractéristique d'une variable aléatoire multivariée est donnée par :  $\phi_{\mu, \Sigma}(t) = \exp(it^\top \mu - \frac{1}{2}t^\top \Sigma t)$ .

En appliquant la transformation :

$$\begin{aligned} \phi_Y(t) &= E[\exp(it^\top X)] \\ &= E[\exp(it^\top (\Sigma_y^{1/2}X + \mu))] \\ &= \exp(it^\top \mu) \times E[\exp(it^\top (\Sigma_y^{1/2}X))] \\ &= \exp(it^\top \mu) \times \phi_X(\Sigma_y^{1/2}t) \\ &= \exp(it^\top \mu) \times E[\exp(-\frac{1}{2}t^\top \Sigma t)] \\ &= \exp(it^\top \mu - \frac{1}{2}t^\top \Sigma t). \end{aligned}$$

Le résultat correspond bien à la fonction caractéristique d'une variable aléatoire  $Y \sim N(\mu, \Sigma)$ .

### 2.3 Manipulation 3

On génère 1000 échantillons de la variable aléatoire  $Y$ , on obtient une matrice  $2 \times 1000$ , dont la première ligne correspond aux échantillons de la variable aléatoire  $Y_1$  et la deuxième à ceux de  $Y_2$ . À l'aide de `mean` et `cov`, on obtient des valeurs des espérance et covariances expérimentales proches aux valeurs théoriques  $\sim 0.2$ ,  

$$\sim \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

### 2.4 Manipulation 4

On obtient les histogrammes représentés sur les figures ci-dessous. Les histogrammes sont bien centrés selon les deux axes en leurs moyennes respectives, ( $0_2$  pour  $X$  et  $\mu$  pour  $Y$ ). De plus, on remarque que l'histogramme du vecteur gaussien  $Y$  forme une ellipse et celui de  $X$  forme un cercle ; c'est les covariances non nulles, qui représentent la non indépendance entre  $Y_1$  et  $Y_2$ , qui sont à l'origine de cette différence.




FIGURE 1 – Histogramme 2D de  $Y$




FIGURE 2 – Vu de haut




FIGURE 3 – Histogramme 2D de  $X$




FIGURE 4 – Vu de haut

## 2.5 Manipulation 5

On obtient la matrice suivante :  $\sim \begin{bmatrix} 1 & 0.96 \\ 0.96 & 1 \end{bmatrix}$  On en déduit donc que le coefficient de corrélation du couple  $(X, Y) \approx 0.96$  : les deux variables aléatoires sont donc corrélées.

## 3 Mesures quantitatives

### 3.1 Manipulations 6 et 7

$X_1$  est le vecteur représentant les enregistrements des hauteurs des précipitations relevées dans la ville de Bordeaux,  $X_2$  dans Nantes et  $X_3$  dans San Tiago.

En modélisant ces données comme étant des variables aléatoires, on peut trouver numériquement la corrélation entre les précipitations de ces trois villes respectives.

On calcule la matrice de covariance de  $X_1$  et  $X_2$  :

$$\begin{bmatrix} \text{var}(X_1) = 65.0000 & \text{cov}(X_1, X_2) = 35.0000 \\ \text{cov}(X_1, X_2) = 35.0000 & \text{var}(X_2) = 65.0000 \end{bmatrix}$$

En comparant les valeurs de variance et de covariance, on en déduit que les hauteurs des précipitations de Bordeaux et Nantes sont fortement corrélées, ce qui est logique au vu du fait que les deux villes sont proches. ( $\sim 350km$ ).

En calculant la matrice de covariance de  $X_1$  et  $X_3$  on obtient :

$$\begin{bmatrix} 65.0000 & 0.1090 \\ 0.1090 & 67.0723 \end{bmatrix}$$

On trouve dans ce cas que  $\text{cov}(X_1, X_3) \approx 0$ , ce qui veut dire que ces données sont peu corrélées, si ce n'est pas corrélées. La distance entre la ville de Bordeaux et San Tiago est de  $9,273km$ , c'est ce qui explique l'indépendance entre  $X_1$  et  $X_2$ .

On retrouve à peu près le même résultat pour  $X_2$  et  $X_3$ .

### 3.2 Manipulation 8

L'expression de l'information mutuelle de deux variables aléatoires bivariées s'écrit :

$$I(X, Y) = H(X) + H(Y) - H(X, Y)$$

Il nous faut alors trouver un moyen de calculer l'entropie conjointe du couple  $(X, Y)$ . Dans le cas de  $X_3$  et  $X_2$ ,  $X_2$  et  $X_3$ ,  $I(X)$  sera nulle au vu de l'indépendance.

```

close all
clear
clc

%% Manipulations 1,2

% Paramètres
N = 1000;
u=2 ; sigma =3;
Realisations = u + sigma * randn(N,1);
y = -15:0.1:15;
f = exp(-(y-u).^2./(2*sigma^2))./(sigma*sqrt(2*pi));

% Figures
figure, hist = histogram(Realisations, 'Normalization','pdf');
hold on
plot(y, f, 'Linewidth', 1.5); xlabel('X'), ylabel('P(X=x)');
title("Histogramme et fonction densité d'une variable aléatoire gaussienne");
legend('Histogramme', 'Densité');
H= calcul_entropie(hist);

%% Manipulations 3,4,5

% Paramètres
X = randn(2,N);
A = [2 1; 1 2]; [U,D] = eig(A); B = U*D.^(0.5)*U';
mu = [0.2 0.2]';
Y = B*X + mu;
m_1 = mean(Y(1,:)); m_2 = mean(Y(2,:)); covv = cov(Y(1,:),Y(2,:)); %Vérification
XT = X.'; YT = Y.';
corrcoefXY = corrcoef(YT(:,1),XT(:,1));

% Figures
figure, h = histogram2(Y(1,:),Y(2,:), 'Normalization','pdf');
h.FaceColor = 'flat';
xlabel('Y_1'), ylabel('Y_2');
zlabel('Probabilité') ;
title("Histogramme bivariée de Y");
figure,
h1 = histogram2(X(1,:), X(2,:), 'Normalization','pdf');
xlabel('X_1'), ylabel('X_2');
zlabel('Probabilité') ;
title("Histogramme bivariée de X");
h1.FaceColor = 'flat';

%% Manipulation 6,7,8

% Paramètres
load X_pluv.mat
X1 = X_pluv(:,1); % Bordeaux
X2 = X_pluv(:,2); % Nantes
X3 = X_pluv(:,3); % Santiago

Y1 = [X1, X2]; Y2 = [X1, X3]; Y3 = [X2, X3];
cov1 = cov(Y1); cov2 = cov(Y2); cov3 = cov(Y3);

%% Functions
% Entropie
function H=calcul_entropie(hist)
H = 0;
number_bins = hist.NumBins;
values = hist.Values;
width = hist.BinWidth;
for i=1:number_bins
if (values(i) ~= 0)
H = H - values(i)*width*log(values(i));
end
end
end

```

